课后习题（2026 春）-参考答案

第三章-线性分类课后作业

1. 假设有两维的输入数据，感知机的线性判别函数为 $f(x)=w^Tx+b$，初始参数为 $w=[0,0]^T$，偏置为 $b=0$。感知机优化的总体目标函数为：

$$J(w,b)=\sum_{x_i\in E}-y_i(w^Tx_i+b)$$

其中 E 为误分类样本的集合。优化过程的学习率（步长）为 $\eta=1$，训练样本如下：

- 样本 1：输入 $x_1=[1,2]^T$，标签 $y_1=1$
- 样本 2：输入 $x_2=[2,3]^T$，标签 $y_2=-1$
- 样本 3：输入 $x_3=[-1,-1]^T$，标签 $y_3=1$

现在按照随机梯度下降（SGD）的方式进行模型学习，即每次遇到一个误分类样本 (x_i,y_i) 时进行参数更新。参数更新规则如下：

$$w\leftarrow w+\eta y_ix_i,$$
$$b\leftarrow b+\eta y_i$$

请给出 6 步迭代后的线性判别函数。

【解】

初始化：权重向量 $w_0=[0,0]^T$，偏置 $b_0=0$，学习率 $\eta=1$。判别条件：若 $y_i(w^Tx_i+b)\le 0$，则判定为误分类，需要更新参数。

- **第 1 步**：取样本 1 $(x_1=[1,2]^T,y_1=1)$
  - **判别：** $y_1(w_0^Tx_1+b_0)=1\times([0,0][1,2]^T+0)=0$
  - **结论：**结果 ≤ 0，属于误分类，**更新参数**。
  - **更新：**

$$w_1=w_0+1\cdot y_1\cdot x_1=[0,0]^T+1\cdot[1,2]^T=[1,2]^T$$

$$b_1=b_0+1\cdot y_1=0+1=1$$

  - **当前参数：** $w_1=[1,2]^T,b_1=1$

- **第 2 步**：取样本 2 $(x_2 = [2,3]^T, y_2 = -1)$
  - **判别：** $y_2(w_1^T x_2 + b_1) = -1 \times ([1,2][2,3]^T + 1) = -1 \times (2+6+1) = -9$
  - **结论：** $-9 \leq 0$，属于误分类，**更新参数**。
  - **更新：**

$$w_2 = w_1 + 1 \cdot y_2 \cdot x_2 = [1,2]^T + (-1) \cdot [2,3]^T = [-1,-1]^T$$

$$b_2 = b_1 + 1 \cdot y_2 = 1 + (-1) = 0$$

  - **当前参数：** $w_2 = [-1,-1]^T, b_2 = 0$

- **第 3 步**：取样本 3 $(x_3 = [-1,-1]^T, y_3 = 1)$
  - **判别：** $y_3(w_2^T x_3 + b_2) = 1 \times ([-1,-1][-1,-1]^T + 0) = 1 \times (1+1) = 2$
  - **结论：** $2 > 0$，分类正确，**不更新**。
  - **参数保持：** $w_3 = w_2 = [-1,-1]^T, \quad b_3 = b_2 = 0$

第一轮遍历结束，开始第二轮遍历：

- **第 4 步**：再次取样本 1 $(x_1 = [1,2]^T, y_1 = 1)$
  - **判别：** $y_1(w_3^T x_1 + b_3) = 1 \times ([-1,-1][1,2]^T + 0) = 1 \times (-1-2) = -3$
  - **结论：** $-3 \leq 0$，属于误分类，**更新参数**。
  - **更新：**

$$w_4 = w_3 + 1 \cdot y_1 \cdot x_1 = [-1,-1]^T + [1,2]^T = [0,1]^T$$

$$b_4 = b_3 + 1 \cdot y_1 = 0 + 1 = 1$$

  - **当前参数：** $w_4 = [0,1]^T, b_4 = 1$

- **第 5 步**：再次取样本 2 $(x_2 = [2,3]^T, y_2 = -1)$
  - **判别：** $y_2(w_4^T x_2 + b_4) = -1 \times ([0,1][2,3]^T + 1) = -1 \times (0+3+1) = -4$
  - **结论：** $-4 \leq 0$，属于误分类，**更新参数**。
  - **更新：**

$$w_5 = w_4 + 1 \cdot y_2 \cdot x_2 = [0,1]^T - [2,3]^T = [-2,-2]^T$$

$$b_5 = b_4 + 1 \cdot y_2 = 1 - 1 = 0$$

  - **当前参数：** $w_5 = [-2,-2]^T, b_5 = 0$

- **第 6 步**：再次取样本 3 $(x_3 = [-1,-1]^T, y_3 = 1)$
  - **判别：** $y_3(w_5^T x_3 + b_5) = 1 \times ([-2,-2][-1,-1]^T + 0) = 1 \times (2+2) = 4$
  - **结论：** $4 > 0$，分类正确，**不更新**。
  - **最终参数：** $w_6 = [-2,-2]^T, \quad b_6 = 0$

最终判别函数为：

$$f(x) = -2x^{(1)} - 2x^{(2)}$$

2. （判断题）对于两类线性判别问题，当两类样本的类内散度矩阵相同时 ($S_1 = S_2$)，Fisher 最优判别矢量 w 的方向与连接两类均值向量的直线方向 ($\mu_1 - \mu_2$ 的方向) 一致。（　）

【解】错误。

解析： Fisher 线性判别分析（LDA）的最优投影方向 w 由下式决定：

$$w = S_w^{-1}(\mu_1 - \mu_2)$$

其中 $S_w = S_1 + S_2$ 是总类内散度矩阵。即使 $S_1 = S_2$，总类内散度矩阵 $S_w = 2S_1$ 通常也不是单位矩阵（或单位矩阵的倍数）。矩阵 S_w^{-1} 会对向量 $(\mu_1 - \mu_2)$ 进行仿射变换（旋转和缩放）。

因此，只有当协方差矩阵与单位矩阵成比例（即数据分布是各向同性的球形分布）时，w 的方向才与连接两类均值的直线方向一致。在一般情况下，两者方向并不相同。

3. 在逻辑回归（Logistic Regression）模型中，假设输入向量为 $x \in \mathbb{R}^d$，权重向量为 $w \in \mathbb{R}^d$，偏置为 b。样本属于正类（$y = 1$）的后验概率定义为：

$$P(y = 1|x) = \sigma(w^T x + b) = \frac{1}{1 + e^{-(w^T x + b)}}$$

(1) 假设对于一个二维数据点 $x = [1, 1]^T$，已知模型参数 $w = [1, -1]^T$，$b = 0$。请计算该数据点被预测为正类（$y = 1$）的概率。

(2) 证明 Sigmoid 函数 $\sigma(z) = \frac{1}{1+e^{-z}}$ 的导数满足：$\sigma'(z) = \sigma(z)(1 - \sigma(z))$。

【解】

(1) 首先计算线性部分 $w^T x + b$：

$$w^T x + b = [1, -1] \begin{bmatrix} 1 \\ 1 \end{bmatrix} + 0 = 1 \times 1 + (-1) \times 1 = 0$$

代入 Sigmoid 函数中计算概率：

$$P(y = 1|x) = \frac{1}{1 + e^{-0}} = \frac{1}{1 + 1} = 0.5$$

(2) **证明：**根据链式法则对 $\sigma(z) = (1 + e^{-z})^{-1}$ 求导：

$$\begin{aligned} \sigma'(z) &= -1 \cdot (1 + e^{-z})^{-2} \cdot \frac{d}{dz}(1 + e^{-z}) \\ &= -(1 + e^{-z})^{-2} \cdot (-e^{-z}) \\ &= \frac{e^{-z}}{(1 + e^{-z})^2} \end{aligned}$$

将其拆分为两项相乘：

$$\begin{aligned}\sigma'(z) &= \frac{1}{1+e^{-z}} \cdot \frac{e^{-z}}{1+e^{-z}} \\ &= \sigma(z) \cdot \frac{1+e^{-z}-1}{1+e^{-z}} \\ &= \sigma(z) \cdot \left(1 - \frac{1}{1+e^{-z}}\right) \\ &= \sigma(z)(1-\sigma(z))\end{aligned}$$

证毕。

4. 给定一个二维平面上的简单二分类数据集，包含三个样本：
正类样本（$y=1$）：$x_1=[2,2]^T$
负类样本（$y=-1$）：$x_2=[0,0]^T, x_3=[2,0]^T$
我们希望训练一个硬间隔支持向量机（Hard Margin SVM），寻找最优超平面 $w^Tx+b=0$。
(1) 直观写出该数据集的最大间隔超平面的方程（即求出 w 和 b）。
(2) 指出该模型中的“支持向量”是哪几个样本?
(3) 计算这个最优超平面的几何间隔（Margin）是多少?

【解】

(1) 将样本画在二维坐标平面上，可以发现正类样本点纵坐标为 2，负类样本点纵坐标均为 0。要使得分类超平面距离正负类的间距最大，该超平面必然平行于 $x^{(1)}$ 轴，且正好穿过正负类纵坐标的中间位置，即 y 坐标为 1 的水平线。因此最大间隔超平面的方程为：$x^{(2)}=1$，即：

$$0 \cdot x^{(1)} + 1 \cdot x^{(2)} - 1 = 0$$

对应参数为：$w=[0,1]^T, b=-1$。

(2) 支持向量是指距离超平面最近的样本点。

- 对于 $x_1=[2,2]^T$，距离 $d_1=\frac{|w^Tx_1+b|}{\|w\|}=\frac{|2-1|}{1}=1$
- 对于 $x_2=[0,0]^T$，距离 $d_2=\frac{|0-1|}{1}=1$
- 对于 $x_3=[2,0]^T$，距离 $d_3=\frac{|0-1|}{1}=1$

可以看出，所有三个样本 x_1, x_2, x_3 到超平面的距离都相等且达到最小，因此**这三个样本全是支持向量**。

(3) 几何间隔（Margin）为支持向量到超平面的距离：

$$\gamma = \frac{1}{\|w\|} = \frac{1}{\sqrt{0^2+1^2}} = 1$$

5. 很多线性分类模型可以统一看作是优化“经验风险最小化”问题，其区别主要在于使用了不同的替代损失函数（Surrogate Loss Function）。对于样本 (x_i, y_i)，令其函数间隔（margin）为 $z = y_i f(x_i)$。请将下列机器学习算法与它们所使用的损失函数对应起来，并简述理由。

算法：

A. 感知机 (Perceptron)

B. 逻辑回归 (Logistic Regression)

C. 线性支持向量机 (Linear SVM)

损失函数：

1. Hinge Loss: $L(z) = \max(0, 1 - z)$
2. Cross Entropy (Log Loss): $L(z) = \log(1 + e^{-z})$
3. Perceptron Loss: $L(z) = \max(0, -z)$

【解】

对应关系与理由：

- **A** $\rightarrow$ **3**（感知机 $\leftrightarrow$ Perceptron Loss）：感知机只对误分类的样本进行惩罚。当 $z < 0$（分类错误）时，惩罚随 $-z$ 线性增加；当 $z \geq 0$（分类正确）时，损失为 0，没有进一步的约束。
- **B** $\rightarrow$ **2**（逻辑回归 $\leftrightarrow$ Cross Entropy）：逻辑回归采用最大似然估计，其目标函数等价于最小化交叉熵损失。$\log(1 + e^{-z})$ 是一条处处可导的光滑曲线，是对 0-1 损失函数的凸近似。
- **C** $\rightarrow$ **1**（支持向量机 $\leftrightarrow$ Hinge Loss）：SVM 不仅要求分类正确，还要求有一个“裕度”（Margin）。因此，只有当 $z \geq 1$ 时损失才为 0；如果 $0 < z < 1$，虽然分类正确但裕度不够，依然会产生损失。这是 SVM 形成支持向量的关键。

6. 现有四个二维样本点构成异或（XOR）问题的数据集：
正类（$y = 1$）：$[0,1]^T, [1,0]^T$
负类（$y = -1$）：$[0,0]^T, [1,1]^T$
请问感知机模型能否在这个数据集上收敛？请简述原因，并提出一种可以将此数据集完美分类的方法。

【解】

能否收敛：不能收敛。

原因：异或（XOR）问题的数据在二维空间中是**线性不可分**的。即不存在一条直线可以将正类和负类完美地分割开来。根据 Novikoff 定理（感知机收敛定理），感知机学习算法只有在训练数据集线性可分时，才能保证在有限步内收敛；若数据线性不可分，感知机的参数更新将陷入死循环，不断震荡。

解决方案（提出任意一种即可）：

(a) **引入非线性特征映射（或者核方法）：**将数据映射到更高维的空间。例如增加一个特征 $x^{(3)} = x^{(1)} \cdot x^{(2)}$，在这个三维空间中数据将变得线性可分。

(b) **多层感知机（神经网络）：**引入至少包含一个隐藏层的多层感知机（MLP），使用非线性激活函数，能够拟合出非线性的决策边界来解决 XOR 问题。