课后习题（2026 春）-参考答案

第二章-贝叶斯

1. 现有一垃圾邮件过滤器，已知收件箱中垃圾邮件的占比为 30%，正常邮件的占比为 70%。假设在此条件下，“邮件包含关键词中奖”与“邮件包含关键词发票”为条件独立，且各个关键词在不同类型邮件中的出现概率如下：

   - 关键词“中奖”：
     - 在垃圾邮件中出现的概率为 50%，未出现的概率为 50%
     - 在正常邮件中出现的概率为 0.1%，未出现的概率为 99.9%
   - 关键词“发票”：
     - 在垃圾邮件中出现的概率为 20%，未出现的概率为 80%
     - 在正常邮件中出现的概率为 5%，未出现的概率为 95%

   现收到一封同时包含“中奖”和“发票”的邮件，请使用贝叶斯决策器判断这封邮件的类型，计算这封邮件是垃圾邮件的后验概率的具体数值（百分比）。

   解：设 S 表示垃圾邮件（Spam），H 表示正常邮件（Ham）。设 W 表示关键词“中奖”，I 表示关键词“发票”。

   根据题意，先验概率为：

   $$P(S) = 0.3, \quad P(H) = 0.7$$

   类条件概率为：

   $$P(W|S) = 0.5, \quad P(W|H) = 0.001$$

   $$P(I|S) = 0.2, \quad P(I|H) = 0.05$$

   假设关键词之间条件独立，对于一封同时包含“中奖”和“发票”的邮件 $x = \{W, I\}$，我们需要计算其后验概率。根据贝叶斯公式：

   $$P(S|x) = \frac{P(W,I|S)P(S)}{P(x)} = \frac{P(W|S)P(I|S)P(S)}{P(x)}$$

   $$P(H|x) = \frac{P(W,I|H)P(H)}{P(x)} = \frac{P(W|H)P(I|H)P(H)}{P(x)}$$

   由于分母 $P(x)$ 对两类相同，只需比较分子（即判别函数值）：

垃圾邮件的得分为：

$$\begin{aligned} Score(S) &= P(W|S) \times P(I|S) \times P(S) \\ &= 0.5 \times 0.2 \times 0.3 \\ &= 0.03 \end{aligned}$$

正常邮件的得分为：

$$\begin{aligned} Score(H) &= P(W|H) \times P(I|H) \times P(H) \\ &= 0.001 \times 0.05 \times 0.7 \\ &= 0.000035 \end{aligned}$$

结论：因为 $Score(S) > Score(H)$（即 $0.03 > 0.000035$），根据贝叶斯决策规则，判断该邮件为**垃圾邮件**。这封邮件是垃圾邮件的后验概率的具体数值 $\frac{0.03}{0.03+0.000035} \approx 99.88\%$

2. 两分类问题中，各类样本的类别条件概率均为多元正态分布，多元正态分布的表达式如下：

$$p(x) = \frac{1}{(2\pi)^{d/2}|\Sigma|^{1/2}} \exp\left[-\frac{1}{2}(x-\mu)^T\Sigma^{-1}(x-\mu)\right]$$

写出两类的对数似然比（或判别函数）表达式。采用贝叶斯分类方法分类时，什么情况下决策界为线性？什么情况下决策界为非线性?

解：

在贝叶斯分类中，假设类条件概率 $p(x|\omega_i)$ 服从多元正态分布 $N(\mu_i,\Sigma_i)$。判别函数 $g_i(x)$ 通常取对数形式：

$$g_i(x) = \ln p(x|\omega_i) + \ln P(\omega_i)$$

$$g_i(x) = -\frac{1}{2}(x-\mu_i)^T\Sigma_i^{-1}(x-\mu_i) - \frac{d}{2}\ln(2\pi) - \frac{1}{2}\ln|\Sigma_i| + \ln P(\omega_i)$$

决策界由 $g_i(x) = g_j(x)$ 确定。

- **决策界为线性的情况：**当各类别的**协方差矩阵相等**（即 $\Sigma_i = \Sigma_j = \Sigma$）时。此时，展开式中的二次项 $x^T\Sigma^{-1}x$ 在 $g_i(x) - g_j(x)$ 中相互抵消，剩下的仅是 x 的线性项。因此，决策界是一个超平面（线性）。
- **决策界为非线性的情况：**当各类别的**协方差矩阵不相等**（即 $\Sigma_i \neq \Sigma_j$）时。此时，二次项 $x^T\Sigma_i^{-1}x$ 和 $x^T\Sigma_j^{-1}x$ 无法抵消，判别函数差包含 x 的二次项。因此，决策界是超二次曲面（非线性）。

3. 现有一枚有偏硬币（投掷结果正、反面概率不一样），每次随机投掷都是独立的。投掷 20 次的观测结果如下：

反正正正反正正正正反正反正正反正正反正正

请估计下一次投掷正面朝上的概率（单次投掷服从伯努利分布）。要求写出建模过程，以及参数估计过程。

解：

1. 建模过程：设硬币正面朝上为事件 1，反面朝上为事件 0。设投掷结果服从参数为 θ 的伯努利分布（Bernoulli Distribution），其中 θ 为正面朝上的概率。概率质量函数为：

$$P(x|\theta) = \theta^x(1-\theta)^{1-x}, \quad x \in \{0,1\}$$

2. 参数估计过程（极大似然估计 MLE）：观测数据为 $D = \{x_1, x_2, ..., x_{20}\}$。根据题目给出的序列："反正正正反正正正正反正反正正反正正反正正"，统计得：总次数 $N = 20$。正面次数（正）$N_1 = 14$。反面次数（反）$N_0 = 6$。

似然函数 $L(\theta)$ 为：

$$L(\theta) = \prod_{i=1}^{20} P(x_i|\theta) = \theta^{N_1}(1-\theta)^{N_0} = \theta^{14}(1-\theta)^6$$

对数似然函数 $l(\theta)$ 为：

$$l(\theta) = \ln L(\theta) = 14\ln\theta + 6\ln(1-\theta)$$

对 θ 求导并令导数为 0：

$$\frac{dl(\theta)}{d\theta} = \frac{14}{\theta} - \frac{6}{1-\theta} = 0$$

$$14(1-\theta) = 6\theta$$

$$14 - 14\theta = 6\theta$$

$$20\theta = 14$$

解得估计值：

$$\hat{\theta} = \frac{14}{20} = 0.7$$

结论：估计下一次投掷正面朝上的概率为 **0.7**。