课后习题（2026 春）-参考答案

第六章-聚类

1. 判断：

（1）K-means 聚类算法需要预先指定聚类数 K。（ ）

（2）K-means 对初始聚类中心不敏感，不同初始化一定会得到相同结果。（ ）

（3）K-means 每次迭代都会先分配样本到最近的聚类中心，再更新聚类中心。（ ）

（4）K-means 更适合发现形状近似为凸形或球状的簇。（ ）

（5）层次聚类不需要预先指定聚类数，但可以通过切割树状图得到指定数量的簇。（ ）

（6）聚类是一种监督学习方法，需要训练数据具有类别标签。（ ）

答案：对，错，对，对，对，错。

解析：

- K-means 需要提前给定聚类数 K。
- K-means 对初始聚类中心比较敏感，不同初始化可能得到不同的局部最优结果。
- K-means 的基本迭代过程包括“样本分配”和“中心更新”两个步骤。
- K-means 基于均值和欧氏距离，通常更适合发现凸形、球状、大小相近的簇。
- 层次聚类可以先生成完整的树状图，再根据需要切割得到不同数量的簇。
- 聚类属于无监督学习方法，通常不依赖样本类别标签。

2. 给定如下 6 个二维样本点：

$$A(1,1),\quad B(1,2),\quad C(2,1),\quad D(4,4),\quad E(5,4),\quad F(4,5).$$

使用 K-means 算法进行聚类，设 $K=2$，初始聚类中心为

$$\mu_1^{(0)}=(1,1),\quad \mu_2^{(0)}=(4,4).$$

请完成一次完整迭代，包括样本分配和聚类中心更新。

解：

第一步：样本分配。

分别计算每个样本到两个初始聚类中心的欧氏距离。

$$d(x,\mu)=\sqrt{(x_1-\mu_1)^2+(x_2-\mu_2)^2}.$$

样本	到 $\mu_1^{(0)}=(1,1)$ 的距离	到 $\mu_2^{(0)}=(4,4)$ 的距离	所属簇
$A(1,1)$	0	$\sqrt{18}\approx 4.24$	C_1
$B(1,2)$	1	$\sqrt{13}\approx 3.61$	C_1
$C(2,1)$	1	$\sqrt{13}\approx 3.61$	C_1
$D(4,4)$	$\sqrt{18}\approx 4.24$	0	C_2
$E(5,4)$	5	1	C_2
$F(4,5)$	5	1	C_2

因此，一次分配后得到两个簇：

$$C_1=\{A,B,C\},\quad C_2=\{D,E,F\}.$$

第二步：更新聚类中心。

对 C_1 中样本取均值：

$$\mu_1^{(1)}=\left(\frac{1+1+2}{3},\frac{1+2+1}{3}\right)=\left(\frac{4}{3},\frac{4}{3}\right).$$

对 C_2 中样本取均值：

$$\mu_2^{(1)}=\left(\frac{4+5+4}{3},\frac{4+4+5}{3}\right)=\left(\frac{13}{3},\frac{13}{3}\right).$$

结论：

一次完整迭代后，

$$C_1=\{A,B,C\},\quad C_2=\{D,E,F\},$$

新的聚类中心为

$$\mu_1^{(1)}=\left(\frac{4}{3},\frac{4}{3}\right),\quad \mu_2^{(1)}=\left(\frac{13}{3},\frac{13}{3}\right).$$

3. 简答：

K-means 算法的目标函数是什么？为什么 K-means 算法通常会收敛？

答案：

K-means 的目标是最小化簇内平方误差和，即

$$J=\sum_{j=1}^{K}\sum_{x_i\in C_j}\|x_i-\mu_j\|^2,$$

其中 C_j 表示第 j 个簇，μ_j 表示该簇的聚类中心。

K-means 每次迭代包括两个步骤：

- **样本分配步骤：**在聚类中心固定时，将每个样本分配给距离最近的聚类中心，这不会增大目标函数值。
- **中心更新步骤：**在样本分配固定时，用簇内样本均值作为新的聚类中心，可以使簇内平方误差最小。

因此，K-means 每次迭代都会使目标函数值不增大。由于有限个样本的聚类划分方式是有限的，所以算法通常会在有限步后收敛到一个局部最优解。

需要注意的是，K-means 不一定得到全局最优解，其结果可能受到初始聚类中心的影响。

4. 简答：
比较 K-means、层次聚类方法的主要特点。

答案：

- **K-means：**需要预先指定聚类数 K，算法简单、效率较高，适合处理大规模数据。但它对初始中心和异常值较敏感，并且更适合发现球状或凸形簇。
- **层次聚类：**不一定需要预先指定聚类数，可以通过树状图展示样本之间的层次结构，解释性较强。但当样本数量很大时，计算和存储开销较高。

5. 简答：
在层次聚类中，最小距离、最大距离和平均距离三种类间距离定义分别是什么？它们对聚类结果可能有什么影响?

答案：

设有两个簇 C_i 和 C_j。

1. 最小距离法：

最小距离法也称单链接法，其类间距离定义为

$$d_{\min}(C_i, C_j) = \min_{x \in C_i, z \in C_j} d(x, z).$$

它只关注两个簇中最近的两个样本点，因此容易产生“链式效应”，即一些样本可能因为局部距离较近而被逐渐连接成较长的链状簇。

2. 最大距离法：

最大距离法也称全链接法，其类间距离定义为

$$d_{\max}(C_i, C_j) = \max_{x \in C_i, z \in C_j} d(x, z).$$

它关注两个簇中最远的两个样本点，因此倾向于生成更加紧凑的簇，但对异常点可能较敏感。

3. 平均距离法：

平均距离法定义为两个簇中所有样本点对距离的平均值：

$$d_{\text{avg}}(C_i, C_j) = \frac{1}{|C_i||C_j|} \sum_{x \in C_i} \sum_{z \in C_j} d(x, z).$$

它综合考虑两个簇之间所有样本点对的距离，通常比最小距离法和最大距离法更加折中。

结论：

不同的类间距离定义会影响层次聚类的合并顺序，因此可能得到不同的树状图和不同的最终聚类结果。