课后习题（2026 春）-参考答案

第十章-神经网络

1. 判断：

（1）神经网络中的激活函数用于引入非线性表达能力。（ ）

（2）如果多层神经网络中不使用非线性激活函数，则多个线性层叠加后本质上仍然等价于一个线性变换。（ ）

（3）Sigmoid 激活函数在输入绝对值很大时容易出现梯度消失问题。（ ）

（4）ReLU 激活函数的输出一定在 0 到 1 之间。（ ）

（5）Dropout 在训练时随机丢弃一部分神经元，通常可以缓解过拟合。（ ）

（6）Batch Normalization 在训练阶段和测试阶段的行为完全相同。（ ）

（7）卷积神经网络中的卷积层可以利用局部连接和参数共享减少参数量。（ ）

（8）池化层通常可以降低特征图的空间尺寸，并增强一定的平移不变性。（ ）

（9）学习率越大，模型训练一定越快且效果越好。（ ）

（10）Softmax 函数常用于多分类任务的输出层，将 logits 转换为类别概率分布。（ ）

答案： 对，对，对，错，对，错，对，对，错，对。

解析：

- 激活函数用于引入非线性，否则神经网络即使有很多层，本质上仍然只是线性模型。
- Sigmoid 和 Tanh 等饱和激活函数在输入较大或较小时导数接近 0，容易导致梯度消失。
- ReLU 的定义为 $\max(0,x)$，输出范围是 $[0,+\infty)$，并不是 $[0,1]$。
- Dropout 通过随机丢弃部分神经元减少神经元之间的复杂依赖关系，常用于缓解过拟合。
- Batch Normalization 在训练阶段使用当前 mini-batch 的均值和方差，在测试阶段通常使用训练过程中统计得到的滑动均值和方差。
- 卷积层通过局部感受野和参数共享显著减少参数量，适合处理图像等具有空间结构的数据。
- 池化层可以降低特征图尺寸，减少计算量，并在一定程度上增强模型对局部平移的鲁棒性。
- 学习率过大可能导致损失函数震荡甚至发散，学习率过小则可能导致收敛速度过慢。
- Softmax 常用于多分类任务，将每一类的 logit 转换为非负且和为 1 的概率。

2. 请简述梯度消失和梯度爆炸现象的原因，并分别列举至少一种常见的解决方案。

解答：

- **原因**：在深层神经网络的反向传播过程中，梯度通过链式法则从输出层向前传递。
  - **梯度消失**：若网络使用 Sigmoid 或 Tanh 等饱和激活函数，其导数通常小于 1。多层连乘后，梯度可能呈指数级衰减并趋近于 0，导致浅层参数难以更新。
  - **梯度爆炸**：若网络初始化权重过大，或者网络层数较深，反向传播中梯度多层连乘后可能呈指数级增长，导致参数更新幅度过大，训练不稳定甚至数值溢出。
- **解决方案**：
  - **梯度消失**：使用非饱和激活函数，如 ReLU、Leaky ReLU；使用 Batch Normalization；使用残差连接；在循环神经网络中使用 LSTM 或 GRU。
  - **梯度爆炸**：使用梯度裁剪；采用合适的权重初始化方法，如 Xavier 初始化或 He 初始化；使用 Batch Normalization；适当减小学习率。

3. 假设输入图像的尺寸为 $32 \times 32 \times 3$（宽 × 高 × 通道数）。如果卷积层包含 10 个滤波器，每个滤波器的大小为 5×5，步长为 1，填充为 2。请计算该卷积层输出特征图的尺寸，并计算该卷积层的参数量。

解答： 卷积层输出尺寸的计算公式为：

$$L_{out} = \left\lfloor \frac{L_{in} + 2P - K}{S} \right\rfloor + 1.$$

其中，

$$L_{in} = 32, \quad P = 2, \quad K = 5, \quad S = 1.$$

因此输出宽度为

$$W_{out} = \left\lfloor \frac{32 + 2 \times 2 - 5}{1} \right\rfloor + 1 = 32.$$

输出高度同理：

$$H_{out} = 32.$$

输出通道数等于滤波器数量，因此

$$C_{out} = 10.$$

所以输出特征图尺寸为

$$32 \times 32 \times 10.$$

接下来计算参数量。每个滤波器的尺寸为

$$5 \times 5 \times 3,$$

因此每个滤波器包含

$$5 \times 5 \times 3 = 75$$

个权重参数。

若每个滤波器还有一个偏置项，则每个滤波器共有

$$75 + 1 = 76$$

个参数。

共有 10 个滤波器，因此总参数量为

$$76 \times 10 = 760.$$

结论： 该卷积层输出特征图尺寸为

$$32 \times 32 \times 10,$$

参数量为

$$760.$$

4. 给定一个全连接神经网络层，输入向量为

$$\mathbf{x} = \begin{bmatrix} 1 \\ 2 \end{bmatrix},$$

权重矩阵和偏置向量分别为

$$W = \begin{bmatrix} 1 & -1 \\ 0 & 2 \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} 1 \\ -1 \end{bmatrix}.$$

若该层输出为

$$\mathbf{z} = W\mathbf{x} + \mathbf{b},$$

激活函数为 ReLU，请计算激活后的输出。

解答： 首先计算线性变换：

$$W\mathbf{x} = \begin{bmatrix} 1 & -1 \\ 0 & 2 \end{bmatrix} \begin{bmatrix} 1 \\ 2 \end{bmatrix} = \begin{bmatrix} 1 \times 1 + (-1) \times 2 \\ 0 \times 1 + 2 \times 2 \end{bmatrix} = \begin{bmatrix} -1 \\ 4 \end{bmatrix}.$$

加上偏置项：

$$\mathbf{z} = \begin{bmatrix} -1 \\ 4 \end{bmatrix} + \begin{bmatrix} 1 \\ -1 \end{bmatrix} = \begin{bmatrix} 0 \\ 3 \end{bmatrix}.$$

ReLU 激活函数为

$$ReLU(x) = \max(0, x).$$

因此激活后的输出为

$$ReLU(\mathbf{z}) = \begin{bmatrix} 0 \\ 3 \end{bmatrix}.$$

5. 给定二分类模型的输出 logit 为 $z = 0$，使用 Sigmoid 函数得到预测概率：

$$\hat{y} = \sigma(z) = \frac{1}{1+e^{-z}}.$$

若真实标签为 $y = 1$，二分类交叉熵损失为

$$L = -[y \log \hat{y} + (1-y)\log(1-\hat{y})].$$

请计算预测概率和损失值。

解答： 当 $z = 0$ 时，

$$\hat{y} = \sigma(0) = \frac{1}{1+e^{0}} = \frac{1}{2} = 0.5.$$

由于真实标签为 $y = 1$，交叉熵损失为

$$L = -\log \hat{y} = -\log 0.5.$$

因此

$$L = \log 2 \approx 0.693.$$

结论：

$$\hat{y} = 0.5, \quad L \approx 0.693.$$

6. 给定输入特征图

$$X = \begin{bmatrix} 1 & 3 & 2 & 4 \\ 5 & 6 & 1 & 2 \\ 0 & 2 & 8 & 7 \\ 3 & 1 & 4 & 9 \end{bmatrix}.$$

设卷积核为

$$K = \begin{bmatrix} 1 & 0 \\ 0 & -1 \end{bmatrix}.$$

请回答：

(a) 使用该卷积核对输入特征图进行卷积操作，步长为 1，不使用填充。这里按照深度学习中常用的卷积计算方式，即卷积核不翻转，直接滑动相乘求和。请计算卷积后的输出特征图。

(b) 对第一问得到的输出特征图进行 2×2 最大池化，步长为 1，不使用填充。请计算池化后的输出特征图。

解答：　第一问：卷积计算。

输入特征图大小为 4×4，卷积核大小为 2×2，步长为 1，不使用填充。因此卷积输出的宽和高为

$$L_{out}=\frac{4-2}{1}+1=3.$$

所以卷积后的输出特征图大小为 3×3。

对每个 2×2 区域进行计算：

$$\begin{bmatrix}1&3\\5&6\end{bmatrix}*\begin{bmatrix}1&0\\0&-1\end{bmatrix}=1\times1+3\times0+5\times0+6\times(-1)=-5.$$

$$\begin{bmatrix}3&2\\6&1\end{bmatrix}*\begin{bmatrix}1&0\\0&-1\end{bmatrix}=3-1=2.$$

$$\begin{bmatrix}2&4\\1&2\end{bmatrix}*\begin{bmatrix}1&0\\0&-1\end{bmatrix}=2-2=0.$$

$$\begin{bmatrix}5&6\\0&2\end{bmatrix}*\begin{bmatrix}1&0\\0&-1\end{bmatrix}=5-2=3.$$

$$\begin{bmatrix}6&1\\2&8\end{bmatrix}*\begin{bmatrix}1&0\\0&-1\end{bmatrix}=6-8=-2.$$

$$\begin{bmatrix}1&2\\8&7\end{bmatrix}*\begin{bmatrix}1&0\\0&-1\end{bmatrix}=1-7=-6.$$

$$\begin{bmatrix}0&2\\3&1\end{bmatrix}*\begin{bmatrix}1&0\\0&-1\end{bmatrix}=0-1=-1.$$

$$\begin{bmatrix}2&8\\1&4\end{bmatrix}*\begin{bmatrix}1&0\\0&-1\end{bmatrix}=2-4=-2.$$

$$\begin{bmatrix}8&7\\4&9\end{bmatrix}*\begin{bmatrix}1&0\\0&-1\end{bmatrix}=8-9=-1.$$

因此卷积后的输出特征图为

$$Y=\begin{bmatrix}-5&2&0\\3&-2&-6\\-1&-2&-1\end{bmatrix}.$$

第二问：最大池化计算。

对卷积输出特征图 Y 使用 2×2 最大池化，步长为 1，不使用填充。

输出尺寸为

$$L_{out} = \frac{3-2}{1} + 1 = 2.$$

因此池化后的输出大小为 2×2。

分别计算四个 2×2 区域的最大值：

$$\begin{bmatrix} -5 & 2 \\ 3 & -2 \end{bmatrix}, \quad \max = 3.$$

$$\begin{bmatrix} 2 & 0 \\ -2 & -6 \end{bmatrix}, \quad \max = 2.$$

$$\begin{bmatrix} 3 & -2 \\ -1 & -2 \end{bmatrix}, \quad \max = 3.$$

$$\begin{bmatrix} -2 & -6 \\ -2 & -1 \end{bmatrix}, \quad \max = -1.$$

因此最大池化后的输出特征图为

$$\begin{bmatrix} 3 & 2 \\ 3 & -1 \end{bmatrix}.$$

结论： 卷积输出为

$$\begin{bmatrix} -5 & 2 & 0 \\ 3 & -2 & -6 \\ -1 & -2 & -1 \end{bmatrix},$$

最大池化输出为

$$\begin{bmatrix} 3 & 2 \\ 3 & -1 \end{bmatrix}.$$

7. 简答：
什么是过拟合？在神经网络训练中，可以使用哪些方法缓解过拟合？

解答： 过拟合是指模型在训练集上表现很好，但在验证集或测试集上表现较差的现象。它说明模型可能过度学习了训练数据中的噪声或偶然模式，导致泛化能力较差。

在神经网络训练中，常见的缓解过拟合方法包括：

- **增加训练数据**或使用数据增强；
- 使用 **Dropout**；
- 使用 L_1 或 L_2 **正则化**；

- 使用 **Early Stopping**，即当验证集性能不再提升时提前停止训练；
- 减小模型规模，例如减少网络层数或隐藏单元数量；
- 使用 Batch Normalization，在一定程度上也可能带来正则化效果。

8. 简答：
为什么卷积神经网络相比普通全连接神经网络更适合处理图像数据？

解答： 卷积神经网络更适合处理图像数据，主要原因包括：

- **局部连接：**图像具有明显的局部空间结构，例如边缘、纹理和局部形状。卷积核只连接局部区域，可以更有效地提取局部特征。
- **参数共享：**同一个卷积核在整张图像上滑动使用，相同的特征检测器可以在不同位置检测相同模式，从而大幅减少参数量。
- **平移等变性：**卷积操作可以保留空间位置信息，使得目标在图像中发生位置变化时，卷积特征也会相应移动。
- **池化操作增强鲁棒性：**池化层可以降低空间尺寸，并在一定程度上增强模型对局部平移和扰动的鲁棒性。

因此，相比直接使用全连接网络处理图像，卷积神经网络通常具有更少的参数、更强的特征提取能力和更好的泛化能力。

9. 简答：
交叉熵损失函数为什么常用于分类任务？

解答： 交叉熵损失函数常用于分类任务，是因为它可以度量真实标签分布与模型预测概率分布之间的差异。

对于多分类任务，设真实标签的 one-hot 向量为 $\mathbf{y}$，模型通过 Softmax 得到的预测概率为 $\hat{\mathbf{y}}$，交叉熵损失为

$$L = -\sum_{k=1}^{K} y_k \log \hat{y}_k.$$

如果真实类别为第 c 类，则 $y_c = 1$，其他类别为 0，因此损失可以简化为

$$L = -\log \hat{y}_c.$$

这意味着：

- 如果模型给真实类别分配的概率 $\hat{y}_c$ 越大，损失越小；

- 如果模型给真实类别分配的概率 $\hat{y}_c$ 越小，损失越大。

因此，交叉熵损失能够直接鼓励模型提高正确类别的预测概率，适合用于分类模型训练。

10. 简答：
请比较 Sigmoid、Tanh 和 ReLU 三种激活函数的特点。

解答：

- **Sigmoid：**
$$\sigma(x) = \frac{1}{1+e^{-x}}.$$
输出范围为 $(0,1)$，常用于二分类输出层。但当输入绝对值较大时，函数进入饱和区，梯度接近 0，容易导致梯度消失。
- **Tanh：**
$$\tanh(x) = \frac{e^{x}-e^{-x}}{e^{x}+e^{-x}}.$$
输出范围为 $(-1,1)$，相比 Sigmoid 具有零中心化的优点。但它同样存在饱和区，深层网络中也可能出现梯度消失。
- **ReLU：**
$$ReLU(x) = \max(0,x).$$
计算简单，在 $x>0$ 时梯度为 1，可以缓解梯度消失问题。但当输入长期小于 0 时，神经元可能无法更新，出现“神经元死亡”问题。

总体而言，隐藏层中常用 ReLU 或其变体，二分类输出层中常用 Sigmoid，多分类输出层中常用 Softmax。