课后习题（2026 春）-参考答案

第四章-非线性分类

1. 判断并简要解释：

（1）在构建 ID3 决策树时，划分选择依据为最大化信息增益率（　）

（2）在构建 CART 决策树时，划分选择依据为最大化信息增益（　）

（3）在构建 C4.5 决策树时，划分选择依据为最小化基尼指数（　）

（4）随机森林通常通过 Bootstrap 抽样训练多棵决策树，并在每次划分时随机选择部分特征作为候选特征。（　）

（5）AdaBoost 会在每一轮提高被前一轮分类错误样本的权重。（　）

（6）Boosting 中的多个基学习器可以像 Bagging 一样完全独立并行训练。（　）

（7）随机森林相比单棵决策树，通常可以降低模型方差。（　）（8）针对高方差，低偏差的模型，更应该使用 Bagging 方法而不是 Boosting 方法。（　）（9）KNN 算法中，K 越大，模型越复杂，越容易过拟合。（　）

（10）KNN 算法对不同特征的数值尺度不敏感，因此不需要做标准化。（　）

（11）当特征量纲差异较大时，KNN 通常需要对特征进行标准化或归一化。（　）

答案与解析：

- 错，ID3 算法使用的是**信息增益** (Information Gain)。
- 错，C4.5 算法使用的是**信息增益率** (Information Gain Ratio)。
- 错，CART 分类树使用的是**基尼指数** (Gini Index) 最小化，CART 回归树使用的是平方误差最小化。
- 对，随机森林结合了 Bagging 和特征随机选择。每棵树通常使用 Bootstrap 样本训练，并且在每个节点划分时只从部分特征中选择最优划分特征。
- 对，AdaBoost 会逐轮调整样本权重，使后续基学习器更加关注此前被错误分类的样本。
- 错，Boosting 是串行思想，后一轮学习器依赖前一轮学习结果，因此一般不能像 Bagging 那样完全独立并行训练。
- 对，随机森林通过平均多棵低偏差、高方差的决策树，可以有效降低整体模型的方差。
- 对，**Bagging** 主要用于降低模型的**方差** (Variance)。它通过对训练数据进行重采样（Bootstrap）训练多个模型并求平均，特别适合于高方差、低偏差的强学习器。**Boosting** 主要用于降低模型的**偏差** (Bias)，同时也降低方差。它适合于低方差、高偏差的弱学习器。因此，对于高方差模型，使用 Bagging 是正确的选择。

- 错，对于 KNN，K 越小，模型越容易受到局部样本和噪声点影响，模型复杂度更高，更容易过拟合；K 越大，模型决策边界通常更平滑，偏差增大，方差降低。
- 错，KNN 的分类结果依赖于距离度量。如果某个特征的数值范围远大于其他特征，那么它会在距离计算中占据主导地位。
- 对，因此，在使用 KNN 前，通常需要对不同量纲或不同数值范围的特征进行标准化或归一化处理。

2. 有如下 6 个带标签的样本，特征为二维坐标 (x_1, x_2)，类别分为两类：A 类和 B 类。

   现在有一个待分类样本 $x = (4, 2.5)$，使用 KNN 算法对其进行分类，假设 $K = 3$，请计算该测试样本点的类别。（距离度量使用欧式距离）

   样本数据表：

编号	x_1	x_2	类别
1	1	1	A
2	2	1	A
3	4	3	A
4	5	4	B
5	6	5	B
6	7	3	B

   解：

   待分类样本 $x = (4, 2.5)$。我们需要计算 x 与训练集中各个样本的欧式距离 $d(x, x_i) = \sqrt{(x^{(1)} - x_i^{(1)})^2 + (x^{(2)} - x_i^{(2)})^2}$。

   1. 距离计算：

   - 样本 1 (1, 1, A): $d_1 = \sqrt{(4-1)^2 + (2.5-1)^2} = \sqrt{3^2 + 1.5^2} = \sqrt{9 + 2.25} = \sqrt{11.25} \approx 3.35$
   - 样本 2 (2, 1, A): $d_2 = \sqrt{(4-2)^2 + (2.5-1)^2} = \sqrt{2^2 + 1.5^2} = \sqrt{4 + 2.25} = \sqrt{6.25} = 2.5$
   - 样本 3 (4, 3, A): $d_3 = \sqrt{(4-4)^2 + (2.5-3)^2} = \sqrt{0^2 + (-0.5)^2} = \sqrt{0.25} = 0.5$
   - 样本 4 (5, 4, B): $d_4 = \sqrt{(4-5)^2 + (2.5-4)^2} = \sqrt{(-1)^2 + (-1.5)^2} = \sqrt{1 + 2.25} = \sqrt{3.25} \approx 1.80$
   - 样本 5 (6, 5, B): $d_5 = \sqrt{(4-6)^2 + (2.5-5)^2} = \sqrt{(-2)^2 + (-2.5)^2} = \sqrt{4 + 6.25} = \sqrt{10.25} \approx 3.20$
   - 样本 6 (7, 3, B): $d_6 = \sqrt{(4-7)^2 + (2.5-3)^2} = \sqrt{(-3)^2 + (-0.5)^2} = \sqrt{9 + 0.25} = \sqrt{9.25} \approx 3.04$

   2. 寻找最近的 K=3 个邻居： 按距离从小到大排序，最近的 3 个样本依次为：

   (a) 样本 3 ($d = 0.5$, 类别 A)

   (b) 样本 4 ($d \approx 1.80$, 类别 B)

   (c) 样本 2 ($d = 2.5$, 类别 A)

3. 投票表决：在 3 个最近邻中：

- A 类出现 2 次 (样本 3, 样本 2)
- B 类出现 1 次 (样本 4)

结论：根据多数表决规则，该测试样本点的类别判断为 **A 类**。

3. 有如下 6 个样本，类别为 A 或 B。现在希望使用 ID3 决策树选择根节点划分特征。请分别计算特征 X_1 和 X_2 的信息增益，并判断应优先选择哪个特征作为根节点。

样本数据表：

编号	X_1	X_2	类别
1	0	0	A
2	0	1	A
3	0	1	B
4	1	0	B
5	1	0	B
6	1	1	B

解：

整体数据集中，A 类有 2 个样本，B 类有 4 个样本，因此总体经验熵为

$$H(D) = -\frac{2}{6}\log_2\frac{2}{6} - \frac{4}{6}\log_2\frac{4}{6} \approx 0.918.$$

1. 计算特征 X_1 的信息增益：

当 $X_1 = 0$ 时，有 3 个样本，其中 A 类 2 个，B 类 1 个：

$$H(D_{X_1=0}) = -\frac{2}{3}\log_2\frac{2}{3} - \frac{1}{3}\log_2\frac{1}{3} \approx 0.918.$$

当 $X_1 = 1$ 时，有 3 个样本，全部为 B 类：

$$H(D_{X_1=1}) = 0.$$

因此，按照 X_1 划分后的条件熵为

$$H(D|X_1) = \frac{3}{6} \times 0.918 + \frac{3}{6} \times 0 = 0.459.$$

所以

$$Gain(D, X_1) = H(D) - H(D|X_1) = 0.918 - 0.459 = 0.459.$$

2. 计算特征 X_2 的信息增益：

当 $X_2=0$ 时，有 3 个样本，其中 A 类 1 个，B 类 2 个：

$$H(D_{X_2=0}) = -\frac{1}{3}\log_2\frac{1}{3} - \frac{2}{3}\log_2\frac{2}{3} \approx 0.918.$$

当 $X_2=1$ 时，有 3 个样本，其中 A 类 1 个，B 类 2 个：

$$H(D_{X_2=1}) \approx 0.918.$$

因此

$$H(D|X_2) = \frac{3}{6}\times 0.918 + \frac{3}{6}\times 0.918 = 0.918.$$

所以

$$Gain(D,X_2) = H(D) - H(D|X_2) = 0.918 - 0.918 = 0.$$

结论：因为

$$Gain(D,X_1) > Gain(D,X_2),$$

所以 ID3 决策树应优先选择特征 X_1 作为根节点划分特征。

4. 给定如下 6 个一维样本，使用 CART 分类树进行二分类。候选划分点为相邻样本特征值的中点，即

$$t \in \{1.5, 2.5, 3.5, 4.5, 5.5\}.$$

请计算每个划分点对应的加权基尼指数，并选择最优划分点。

样本数据表：

编号	x	类别
1	1	A
2	2	A
3	3	B
4	4	B
5	5	B
6	6	A

解：

对于一个数据集 D，其基尼指数为

$$Gini(D) = 1 - \sum_k p_k^2.$$

分别计算各候选划分点的加权基尼指数。

- 当 $t = 1.5$ 时：

  左侧为 $\{A\}$，基尼指数为 0；右侧为 $\{A,B,B,B,A\}$，其中 A 类 2 个，B 类 3 个：

$$Gini_R = 1 - \left(\frac{2}{5}\right)^2 - \left(\frac{3}{5}\right)^2 = \frac{12}{25} = 0.48.$$

  因此

$$Gini(t = 1.5) = \frac{1}{6} \times 0 + \frac{5}{6} \times 0.48 = 0.40.$$

- 当 $t = 2.5$ 时：

  左侧为 $\{A,A\}$，基尼指数为 0；右侧为 $\{B,B,B,A\}$，其中 A 类 1 个，B 类 3 个：

$$Gini_R = 1 - \left(\frac{1}{4}\right)^2 - \left(\frac{3}{4}\right)^2 = \frac{6}{16} = 0.375.$$

  因此

$$Gini(t = 2.5) = \frac{2}{6} \times 0 + \frac{4}{6} \times 0.375 = 0.25.$$

- 当 $t = 3.5$ 时：

  左侧为 $\{A,A,B\}$，右侧为 $\{B,B,A\}$。两侧均为 2:1 的类别比例，因此

$$Gini_L = Gini_R = 1 - \left(\frac{2}{3}\right)^2 - \left(\frac{1}{3}\right)^2 = \frac{4}{9}.$$

  所以

$$Gini(t = 3.5) = \frac{3}{6} \times \frac{4}{9} + \frac{3}{6} \times \frac{4}{9} = \frac{4}{9} \approx 0.444.$$

- 当 $t = 4.5$ 时：

  左侧为 $\{A,A,B,B\}$，右侧为 $\{B,A\}$。两侧类别比例均为 1:1，因此

$$Gini_L = Gini_R = 1 - \left(\frac{1}{2}\right)^2 - \left(\frac{1}{2}\right)^2 = 0.5.$$

  所以

$$Gini(t = 4.5) = 0.5.$$

- 当 $t = 5.5$ 时：

  左侧为 $\{A,A,B,B,B\}$，其中 A 类 2 个，B 类 3 个，基尼指数为 0.48；右侧为 $\{A\}$，基尼指数为 0：

$$Gini(t = 5.5) = \frac{5}{6} \times 0.48 + \frac{1}{6} \times 0 = 0.40.$$

结论：

各划分点对应的加权基尼指数为

$$0.40, \quad 0.25, \quad 0.444, \quad 0.50, \quad 0.40.$$

其中最小值为 0.25，对应划分点

$$t = 2.5.$$

因此，CART 分类树应选择 $x \le 2.5$ 与 $x > 2.5$ 作为当前最优划分。

5. 考虑如下异或（XOR）二分类数据：

$$(0,0) \mapsto -1, \quad (0,1) \mapsto +1, \quad (1,0) \mapsto +1, \quad (1,1) \mapsto -1.$$

请回答：

(a) 该数据在原始二维空间中是否线性可分？

(b) 若使用特征映射

$$\phi(x_1,x_2) = \left(x_1, x_2, (x_1 - \frac{1}{2})(x_2 - \frac{1}{2})\right),$$

说明该数据在映射后的三维空间中是否线性可分。

解：

1．原始空间中不可线性分割。

XOR 数据中，$(0,0)$ 和 $(1,1)$ 属于 -1 类，而 $(0,1)$ 和 $(1,0)$ 属于 $+1$ 类。两类样本在二维平面上呈交叉分布，无法用一条直线将两类完全分开。

2．映射到三维空间后可以线性分割。

记第三维特征为

$$z = (x_1 - \frac{1}{2})(x_2 - \frac{1}{2}).$$

分别计算四个样本的 z 值：

$$(0,0) : z = \frac{1}{4}, \quad (1,1) : z = \frac{1}{4},$$
$$(0,1) : z = -\frac{1}{4}, \quad (1,0) : z = -\frac{1}{4}.$$

可以看到，-1 类样本的第三维特征均为正，而 $+1$ 类样本的第三维特征均为负。因此，可以使用如下线性分类函数：

$$f(x) = -z = -(x_1 - \frac{1}{2})(x_2 - \frac{1}{2}).$$

当 $f(x) > 0$ 时判为 $+1$ 类，当 $f(x) < 0$ 时判为 -1 类。该分类函数可以正确分类四个样本。

结论： XOR 数据在原始二维空间中线性不可分，但经过合适的非线性特征映射后，可以在高维空间中线性可分。这也是核方法和支持向量机能够处理非线性分类问题的重要思想。

6. 简答：

某非线性分类模型在训练集上准确率为 99%，但在测试集上准确率只有 70%。请问这通常说明模型存在什么问题？可以采取哪些方法缓解？

答案：

这通常说明模型存在明显的**过拟合**问题。模型在训练集上表现很好，但泛化到未见过的测试样本时表现较差，说明模型可能学习到了训练数据中的噪声或偶然模式。

可能的缓解方法包括：

- 降低模型复杂度，例如限制决策树深度、增大 KNN 中的 K 值、减小神经网络规模等。
- 增加正则化，例如在逻辑回归、SVM 或神经网络中加入 L_1 或 L_2 正则化。
- 使用交叉验证选择超参数，避免只根据训练集表现调参。
- 增加训练数据量，或者使用数据增强方法。
- 对决策树进行剪枝，减少对训练集细节的过度拟合。
- 使用集成方法，如随机森林或 Bagging，降低模型方差。