课后习题（2026 春）-参考答案

第五章-回归分析

1. 在回归分析中，模型的泛化误差可以分解为哪三个部分?

   答案：偏差 (Bias)、方差 (Variance)、噪声 (Noise)。

   解析：泛化误差的分解公式通常表示为：

   $$E = \text{Bias}^2 + \text{Variance} + \text{Noise}$$

   - **偏差 (Bias)**：度量了学习算法的期望预测与真实结果的偏离程度，刻画了算法本身的拟合能力。
   - **方差 (Variance)**：度量了同样大小的训练集的变动所导致的学习性能的变化，刻画了数据扰动所造成的影响。
   - **噪声 (Noise)**：表达了在当前任务上任何学习算法所能达到的期望泛化误差的下界，刻画了学习问题本身的难度。

2. 判断：

   （1）高斯误差条件下的最大似然估计等价于最小二乘估计。（ ）

   （2）当模型过于复杂时，可能在训练集上误差很小，但在测试集上误差较大。（ ）

   （3）R^2 越大，模型一定没有过拟合。（ ）

   （4）当多项式回归的阶数不断增大时，训练误差通常会下降，但测试误差可能先下降后上升。（ ）

   答案：对，对，错，对。

   解析：

   - 高斯误差条件下，最大化似然函数等价于最小化残差平方和，因此最大似然估计等价于最小二乘估计。
   - 如果模型复杂度过高，可能会学习到训练集中的噪声，导致训练误差很小但测试误差较大，即出现过拟合。
   - R^2 较大只能说明模型对某个数据集拟合较好，并不能保证模型没有过拟合。判断是否过拟合还需要比较训练集和测试集表现。
   - 随着多项式阶数增大，模型复杂度提高，训练误差通常会下降；但当阶数过高时，模型可能过拟合，导致测试误差上升。

3. 给定一元线性回归模型

$$\hat{y} = wx + b,$$

其中有如下 3 个训练样本：

$$(1,2), \quad (2,3), \quad (3,5).$$

请使用最小二乘法求解参数 w 和 b。

解：

一元线性回归中，最小二乘解可以表示为

$$w = \frac{\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^{n}(x_i - \bar{x})^2}, \quad b = \bar{y} - w\bar{x}.$$

首先计算均值：

$$\bar{x} = \frac{1+2+3}{3} = 2, \quad \bar{y} = \frac{2+3+5}{3} = \frac{10}{3}.$$

计算分子：

$$\sum_{i=1}^{n}(x_i - \bar{x})(y_i - \bar{y}) = (1-2)(2-\frac{10}{3}) + (2-2)(3-\frac{10}{3}) + (3-2)(5-\frac{10}{3}).$$

即

$$= (-1)\left(-\frac{4}{3}\right) + 0 + \left(\frac{5}{3}\right) = \frac{4}{3} + \frac{5}{3} = 3.$$

计算分母：

$$\sum_{i=1}^{n}(x_i - \bar{x})^2 = (1-2)^2 + (2-2)^2 + (3-2)^2 = 1 + 0 + 1 = 2.$$

因此

$$w = \frac{3}{2} = 1.5.$$

又因为

$$b = \bar{y} - w\bar{x} = \frac{10}{3} - 1.5 \times 2 = \frac{10}{3} - 3 = \frac{1}{3}.$$

结论：最小二乘回归模型为

$$\hat{y} = 1.5x + \frac{1}{3}.$$

4. 给定真实值和模型预测值如下表所示，请计算该回归模型的 MAE 和 MSE。

解：

平均绝对误差 MAE 定义为

$$MAE = \frac{1}{n}\sum_{i=1}^{n}|y_i - \hat{y}_i|.$$

编号	真实值 y	预测值 $\hat{y}$
1	3	2
2	5	5
3	7	8
4	9	10

均方误差 MSE 定义为

$$MSE = \frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2.$$

逐项计算误差：

$$y - \hat{y}: \quad 1,\ 0,\ -1,\ -1.$$

因此绝对误差为

$$|y - \hat{y}|: \quad 1,\ 0,\ 1,\ 1.$$

平方误差为

$$(y - \hat{y})^2: \quad 1,\ 0,\ 1,\ 1.$$

所以

$$MAE = \frac{1+0+1+1}{4} = \frac{3}{4} = 0.75.$$

$$MSE = \frac{1+0+1+1}{4} = \frac{3}{4} = 0.75.$$

结论：该模型的

$$MAE = 0.75, \quad MSE = 0.75.$$

5. 简答：

什么是多项式回归？多项式回归是否一定是非线性模型？

答案：

多项式回归是指在原始特征的基础上构造多项式特征，然后使用线性回归模型进行拟合。例如，一元二次多项式回归可以写作

$$\hat{y} = w_0 + w_1 x + w_2 x^2.$$

三次多项式回归可以写作

$$\hat{y} = w_0 + w_1 x + w_2 x^2 + w_3 x^3.$$

从输入变量 x 的角度看，多项式回归可以拟合非线性关系；但从参数 $w_0, w_1, w_2, \cdots$ 的角度看，模型仍然是线性的。

因此，多项式回归通常被称为**关于输入变量的非线性模型**，但它仍然是**关于参数的线性模型**，可以使用线性回归的最小二乘方法求解。

6. 给定如下关于模型复杂度的描述，请填空：

当模型复杂度较低时，模型往往存在较高的 _____ 和较低的 _____，容易出现 _____；
当模型复杂度较高时，模型往往存在较低的 _____ 和较高的 _____，容易出现 _____。

答案：

当模型复杂度较低时，模型往往存在较高的 偏差 和较低的 方差，容易出现 欠拟合；当模型复杂度较高时，模型往往存在较低的 偏差 和较高的 方差，容易出现 过拟合。

解析：

- 简单模型拟合能力弱，容易产生高偏差，表现为欠拟合。
- 复杂模型对训练数据变化更加敏感，容易产生高方差，表现为过拟合。
- 模型选择的目标是在偏差和方差之间取得平衡，从而获得较好的泛化性能。

7. 简答：为什么在线性回归中，当特征之间存在严重多重共线性时，普通最小二乘估计可能不稳定？可以使用什么方法缓解？

答案：

当特征之间存在严重多重共线性时，说明某些特征之间高度相关。此时，设计矩阵 X 的列之间近似线性相关，导致矩阵 X^TX 接近奇异或条件数很大。

在线性回归中，普通最小二乘解为

$$\hat{\mathbf{w}} = (X^TX)^{-1}X^T\mathbf{y}.$$

如果 X^TX 接近不可逆，那么即使训练数据中存在很小扰动，也可能导致参数估计结果发生很大变化。因此，普通最小二乘估计会变得不稳定。

常见的缓解方法包括：

- 删除高度相关的冗余特征；
- 使用主成分分析等方法进行降维；
- 使用岭回归，在目标函数中加入 L_2 正则化项。

岭回归的解为

$$\hat{\mathbf{w}} = (X^TX + \lambda I)^{-1}X^T\mathbf{y}.$$

加入 λI 后，可以改善矩阵求逆的稳定性，从而缓解多重共线性问题。